Plan prévisionnel

Allan CHARDON - Projet 9 - Sentiment140 et SetFit

Dataset retenu

Sentiment140 : 1,6 million de tweets anglais, avec des labels obtenus par émoticônes. La tâche est binaire : négatif (0) et positif (1 après conversion du label 4). Le corpus permet de comparer une baseline et une méthode utilisant peu de données labellisées.

Modèle envisagé

SetFit avec paraphrase-mpnet-base-v2 adapte un encodeur de phrases par paires, puis entraîne une régression logistique. L'article date du 22 septembre 2022, soit moins de cinq ans. L'hypothèse est de rester compétitif avec 512 tweets par classe, contre 300 000 pour le BiLSTM avec GloVe Twitter 200d.

Références bibliographiques

Tunstall et al. (2022). Efficient Few-Shot Learning Without Prompts. arxiv.org/abs/2209.11055
Jo et al. (2022). SetFit, présentation et exemple de code. huggingface.co/blog/setfit
Laperdon et al. (2023). SetFitABSA, adaptation au sentiment par aspect. huggingface.co/blog/setfit-absa

Explication de votre démarche de test du nouvel algorithme

Je retiendrai des partitions stratifiées : train de 1 525 000 tweets, validation de 25 000 et test initial de 50 000. Du test, j'exclurai les textes présents dans le train ou la validation, ainsi que les répétitions après nettoyage. Le BiLSTM utilisera 300 000 tweets ; SetFit, un tirage équilibré de 1 024 tweets. La validation servira au suivi ; le test commun ne servira pas à choisir les réglages.

Je comparerai le F1 macro, l'accuracy, les erreurs par classe, le budget en données et les temps de calcul. Le notebook contiendra les deux méthodes. La note expliquera la veille, les formules utiles, l'optimisation, l'interprétabilité locale et globale et les limites.

Le dashboard Streamlit proposera un parcours en trois étapes : explorer, prédire, comparer. Les graphiques auront des libellés, des motifs et des alternatives textuelles. Les cinq critères WCAG demandés et le déploiement depuis GitHub seront vérifiés avant livraison.

Réutilisation de code : appels adaptés du Quickstart officiel SetFit 1.1.3 (SST-2) à Sentiment140, un autre dataset. Le blog introductif illustre aussi MPNet sur SentEval-CR. La baseline et les nettoyages reprennent le code du projet. Étapes : validation du plan, préparation, entraînement et comparaison, note, dashboard et soutenance. Plan révisé le 22 octobre 2026.