# Plan prévisionnel

Allan CHARDON - Projet 9 - Sentiment140 et SetFit

## Dataset retenu

Sentiment140 contient 1,6 million de tweets anglais. Les émoticônes donnent les labels : négatif (0) et positif (4, converti en 1). Ce corpus permet de comparer les modèles sur une même tâche, avec des quantités de données différentes.

## Modèle envisagé

Je testerai SetFit avec MPNet, un modèle déjà préentraîné. SetFit l'adapte avec des paires de textes, puis une régression logistique prédit le sentiment. La méthode date de septembre 2022, soit moins de cinq ans. Je chercherai à obtenir un bon score avec 512 tweets par classe, face à un BiLSTM avec GloVe entraîné sur 300 000 tweets.

## Références bibliographiques

Tunstall et al. (2022). Efficient Few-Shot Learning Without Prompts. https://arxiv.org/abs/2209.11055
Jo et al. (2022). SetFit: Efficient Few-Shot Learning Without Prompts. https://huggingface.co/blog/setfit
Laperdon et al. (2023). SetFitABSA, sentiment par aspect. https://huggingface.co/blog/setfit-absa

## Explication de votre démarche de test du nouvel algorithme

Je séparerai les données en entraînement (1 525 000 tweets), validation (25 000) et test initial (50 000), en conservant les proportions des classes. Le BiLSTM utilisera 300 000 tweets ; SetFit, 1 024. Je retirerai du test les textes déjà vus et les répétitions après nettoyage. La validation servira au suivi des modèles et le test commun à la comparaison finale.

Je comparerai le F1 macro, la part de bonnes prédictions, les erreurs par classe, le nombre de données et les temps de calcul. Le notebook contiendra les deux modèles. La note expliquera la méthode, les résultats, l'importance des mots et les limites.

Le dashboard Streamlit permettra d'explorer les tweets, de tester un message et de comparer les modèles. Il proposera des graphiques interactifs et des tableaux. Je prendrai en compte les cinq critères WCAG demandés et le déploiement via GitHub et Streamlit.

Code réutilisé : appels du Quickstart SetFit 1.1.3, adaptés de SST-2 à Sentiment140. Le blog SetFit utilise SentEval-CR. Mon application diffère donc des tutoriels. Étapes : validation du plan, préparation, comparaison des modèles, note, dashboard et soutenance. Tutoriel : https://huggingface.co/docs/setfit/v1.1.3/en/quickstart