Note méthodologique

Classification de sentiments avec SetFit
Allan CHARDON - Projet 9

Je compare le BiLSTM avec GloVe à SetFit avec MPNet pour classer des tweets anglais. SetFit obtient un F1 macro de 0,8163, contre 0,8120, avec 1 024 tweets d'adaptation contre 300 000. Le gain est faible. L'intérêt principal est d'obtenir un score proche avec moins de textes supplémentaires. Résultats du 26 septembre 2026.

Dataset retenu

Sentiment140 contient 1 600 000 tweets anglais de 2009, dont la moitié est négative. Les émoticônes donnent les labels [6], avec des erreurs possibles. Je conserve le texte et le label, en convertissant le positif 4 en 1. Le français et le sentiment neutre ne sont pas évalués.

Partition initiale	Taille	Rôle
Train	1 525 000	Réserve d'entraînement
Validation	25 000	Suivi des modèles
Test	50 000	Évaluation finale

Je retire du test les textes présents dans l'entraînement ou la validation, les répétitions et les textes vides. Le contrôle porte aussi sur les textes nettoyés. Après 2 488 retraits, le test commun contient 47 512 tweets : 23 957 négatifs et 23 555 positifs.

Ce contrôle limite les doublons sans garantir des auteurs ou des périodes différents. Je conserve les partitions utilisées pour entraîner les modèles sauvegardés.

Les concepts de l'algorithme récent

La veille repose sur l'article SetFit de septembre 2022 [1], son blog explicatif [2] et le blog SetFitABSA de décembre 2023 [3]. Ces trois sources ont moins de cinq ans au moment du projet.

SetFit adapte un modèle déjà préentraîné avec peu de textes. Ici, MPNet représente chaque tweet par une liste de 768 nombres, appelée vecteur. Cette représentation tient compte du contexte de la phrase.

Première étape : apprendre avec des paires

Je forme des paires de tweets : cible 1 pour deux sentiments identiques, cible 0 pour deux sentiments différents. Deux tweets négatifs forment donc aussi une paire de même classe. La similarité cosinus mesure la ressemblance entre leurs vecteurs. Le modèle apprend à rapprocher cette mesure de la cible.

La fonction CosineSimilarityLoss [5] mesure l'erreur :

Erreur d'une paire = (similarité − cible)²

Une similarité de 0,8 pour une cible de 1 donne une erreur de 0,04. Le modèle apprend à réduire la moyenne de ces erreurs. Les paires réutilisent les tweets disponibles, sans nouvelle annotation.

Deuxième étape : prédire le sentiment

Une régression logistique apprend ensuite à classer les vecteurs en positif ou négatif. Pour un nouveau tweet, MPNet calcule son vecteur, puis ce classifieur donne la prédiction. Le blog SetFit [2] explique ces deux étapes avec du code et MPNet, sur SentEval-CR.

SetFitABSA [3] adapte la méthode au sentiment par aspect. Après extraction de candidats, un premier SetFit repère les aspects et un second prédit leur sentiment. Un avis peut ainsi être positif sur l'écran et négatif sur la batterie. Cette extension fait partie de la veille, sans être entraînée ici.

L'article pose la méthode, le premier blog montre son utilisation et le second l'adapte à une tâche plus fine. Mon application porte sur Sentiment140. J'ai adapté les appels du Quickstart [4], dont l'exemple utilise SST-2.

La modélisation

Le notebook contient les deux modèles. La graine 42 fixe les tirages aléatoires. Par défaut, il recharge les modèles sauvegardés. Les entraînements restent disponibles et le test ne sert pas à choisir les réglages.

Choix	BiLSTM + GloVe	SetFit + MPNet
Train	300 000 tweets	512 par classe, soit 1 024
Validation	25 000 tweets	1 000 par classe, soit 2 000
Représentation	GloVe 200 dimensions	Phrase de 768 dimensions
Apprentissage	Adam, taux 0,001	Adaptation, taux 0,00002
Entraînement	Lots de 256, 5 époques au plus	Lots de 16, 1 époque, 10 itérations de paires

GloVe fournit les vecteurs des mots. Le BiLSTM lit chaque séquence dans les deux sens, puis prédit le sentiment. Il utilise 30 000 entrées et 40 mots au maximum, pour un maximum observé de 37 après nettoyage. Le dropout de 0,3 désactive temporairement une partie des unités pendant l'apprentissage. Avec l'arrêt anticipé, il limite le surapprentissage. La perte est BCEWithLogitsLoss et le seuil reste à 0,5. Les autres paramètres sont détaillés dans le notebook.

La baseline passe les textes en minuscules et retire davantage de signes. SetFit conserve la casse et la ponctuation, normalise les URL et mentions et transforme les pictogrammes en descriptions. Il retire le signe # sans séparer les mots du hashtag. Le dashboard utilise le même nettoyage SetFit.

Métrique et optimisation

La précision répond à la question : parmi les tweets prédits négatifs, combien le sont réellement ? Le rappel mesure la part de tous les tweets négatifs retrouvés. Le même calcul est fait pour les positifs.

Le F1 combine précision et rappel. Je retiens le F1 macro pour donner la même importance aux deux sentiments :

F1 macro = (F1 négatif + F1 positif) / 2

L'accuracy donne la part totale de prédictions correctes. Pour ces scores, une valeur proche de 1 est préférable.

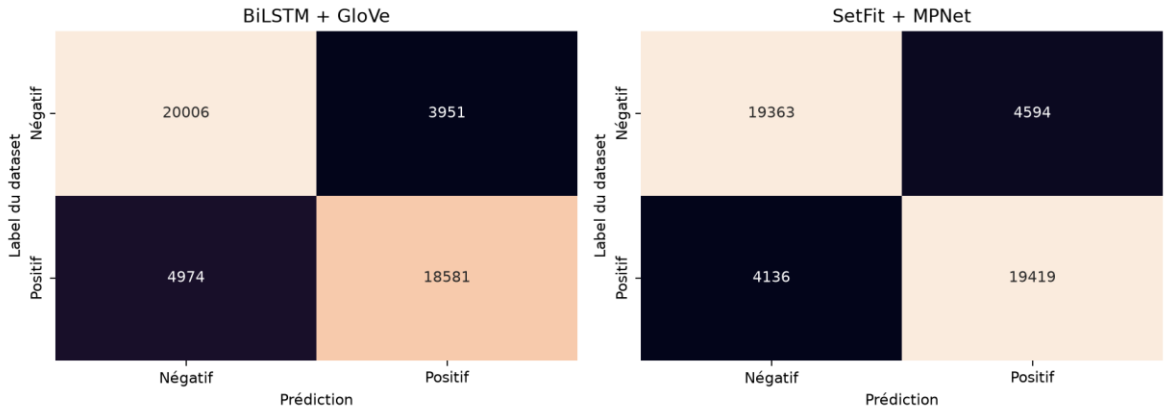
Les pertes servent à apprendre, le F1 à évaluer. Le BiLSTM conserve son meilleur état sur validation, obtenu à la deuxième époque. Pour SetFit, je fixe 512 tweets par classe et des réglages limitant le calcul, puis je vérifie le score de validation. Je n'ai pas comparé systématiquement plusieurs réglages. La longueur de 64 correspond à des sous-mots pendant l'entraînement.

Une synthèse des résultats

Les modèles prédisent les mêmes 47 512 tweets. Le notebook enregistre les résultats, que le dashboard affiche ensuite.

Modèle	Train	Accuracy	F1 macro
BiLSTM + GloVe	300 000	0,8122	0,8120
SetFit + MPNet	1 024	0,8163	0,8163

Le gain de F1 est de 0,427 point de pourcentage. SetFit utilise environ 293 fois moins de tweets pour son adaptation. Ce rapport exclut le préentraînement et la validation. Il ne mesure pas du temps d'annotation économisé.



Dans les matrices, les lignes donnent les labels et les colonnes les prédictions. SetFit retrouve 838 positifs de plus, mais classe aussi 643 négatifs supplémentaires comme positifs, soit 195 bonnes réponses de plus. Le rappel négatif baisse de 83,51 % à 80,82 % : ce point compte si l'objectif est de repérer des plaintes.

Durée	BiLSTM	SetFit
Entraînement historique	697,7 s	2 582,0 s
Inférence du test sur CPU	3,1 s	370,5 s

SetFit est plus lent dans les mesures réalisées. Les durées d'entraînement sont historiques. Les temps de prédiction excluent le chargement et le nettoyage, avec des lots différents. Le choix dépend donc aussi du temps de calcul et des erreurs à éviter.

Interprétabilité globale et locale

Pour expliquer une prédiction, je retire un mot à la fois et observe le changement du score positif.

Je soustrais le score obtenu sans le mot au score du texte complet.

Une différence positive signifie que la présence du mot soutient le positif, une différence négative le négatif. Exemple prédit négatif : My Favourite website is down.

Mot retiré	Variation de probabilité positive
down	−0,9961
website	−0,9959
is	−0,0085

Retirer down augmente fortement le score positif : sa présence contribue donc au négatif. L'effet fort de website montre aussi que retirer un mot peut déformer le contexte.

Pour l'explication globale, je répète l'analyse sur 100 tweets, dont 50 de chaque classe. Je moyenne l'amplitude des changements, quel que soit leur signe, pour les mots présents au moins trois fois.

Mot	Amplitude moyenne de l'effet	Occurrences
see	0,3463	3
down	0,3325	3
didn't	0,3322	3
when	0,3290	3
want	0,3258	3

Ce classement décrit seulement cet échantillon. Retirer un mot ne prouve pas une cause. Les scores ne sont pas vérifiés comme probabilités fiables. Un échantillon plus large permettrait de vérifier la stabilité des effets. Le nuage de mots montre des fréquences, pas l'importance pour le modèle.

Les limites et les améliorations possibles

Les labels sont automatiques et les tweets anciens. Les modèles n'ont pas les mêmes représentations, nettoyages et budgets : l'écart ne mesure donc pas seulement l'effet de SetFit. La validation initiale contient 421 textes présents dans l'entraînement. Je dispose d'un seul entraînement par modèle.

Je supprimerais les doublons avant l'entraînement, puis comparerais les modèles avec autant de données et plusieurs tirages. Un test récent annoté à la main serait utile. Comparer MPNet avant et après adaptation aiderait à mesurer l'apport de SetFit. Enfin, je vérifierais la fiabilité des probabilités et la stabilité des explications sur davantage de textes.

Dashboard et parcours utilisateur

L'utilisateur explore les tweets avec des filtres et des graphiques interactifs, teste un message, puis compare les modèles. Il peut ainsi répondre à trois questions : quelles données, quel sentiment et quel modèle choisir ? Des tableaux donnent aussi les valeurs des graphiques.

Les cinq critères WCAG demandés [7] sont pris en compte : descriptions et texte alternatif (1.1.1), libellés et motifs avec les couleurs (1.4.1), contrastes renforcés (1.4.3), agrandissement à 200 % (1.4.4) et titre de page descriptif (2.4.2). Les contrôles locaux ne constituent pas une certification complète.

Hugging Face héberge les fichiers du modèle. Streamlit calcule les prédictions et le déploiement passe par GitHub et Streamlit Community Cloud. Le parcours sur l'URL publique doit être vérifié avant la démonstration.

Références

[1] Tunstall, L. et al. (2022). Efficient Few-Shot Learning Without Prompts. arXiv:2209.11055. https://arxiv.org/abs/2209.11055

[2] Jo, U. E. S. et al. (2022). SetFit: Efficient Few-Shot Learning Without Prompts. Hugging Face, 26 septembre. https://huggingface.co/blog/setfit

[3] Laperdon, R. et al. (2023). SetFitABSA: Few-Shot Aspect Based Sentiment Analysis using SetFit. Hugging Face, 6 décembre. https://huggingface.co/blog/setfit-absa

[4] Hugging Face. SetFit 1.1.3, Quickstart. https://huggingface.co/docs/setfit/v1.1.3/en/quickstart

[5] Sentence Transformers. CosineSimilarityLoss, documentation. https://www.sbert.net/docs/package_reference/sentence_transformer/losses.html#cosinesimilarityloss

[6] Go, A., Bhayani, R. et Huang, L. (2009). Twitter Sentiment Classification using Distant Supervision. https://cs.stanford.edu/people/alecmgo/papers/TwitterDistantSupervision09.pdf

[7] W3C. Web Content Accessibility Guidelines 2.1. https://www.w3.org/TR/WCAG21/