Note méthodologique

Classification de sentiments avec SetFit
Allan CHARDON - Projet 9 - Révision du 22 octobre 2026

SetFit obtient un F1 macro de 0,8163 contre 0,8120 pour le BiLSTM. Le gain est faible ; l'intérêt principal est le budget de train réduit : 1 024 tweets contre 300 000. Les résultats proviennent des modèles existants, évalués le 26 septembre 2026.

Dataset retenu

Sentiment140 contient 1 600 000 tweets anglais de 2009, répartis entre 800 000 négatifs et 800 000 positifs. Les labels proviennent d'émoticônes : ils sont abondants mais potentiellement bruités. Le notebook charge le texte et le label, puis convertit le label positif 4 en 1. Le neutre et le français ne sont pas évalués.

Partition initiale	Taille	Rôle
Train	1 525 000	Réserve d'entraînement
Validation	25 000	Suivi des modèles
Test	50 000	Évaluation finale

Le contrôle retire du test les textes présents dans le train ou la validation, les chevauchements après nettoyage, les répétitions internes et les textes vides. Les 2 488 retraits donnent un test commun de 47 512 tweets : 23 957 négatifs et 23 555 positifs. Le filtrage repose sur les textes, pas sur les résultats des modèles.

Ce test reste un sous-ensemble du corpus d'origine. Il réduit une fuite observable sans garantir l'indépendance par auteur ou période. Les partitions initiales sont conservées pour retrouver les données des modèles sauvegardés.

Les concepts de l'algorithme récent

La veille retient trois sources liées : l'article de recherche SetFit du 22 septembre 2022, le blog explicatif Hugging Face du 26 septembre 2022 et son adaptation SetFitABSA du 6 décembre 2023. L'article reste la référence scientifique ; les blogs des auteurs facilitent sa compréhension et son application.

Article SetFit, Tunstall et al. (2022). Le principe est d'adapter un encodeur de phrases déjà préentraîné avec peu de textes labellisés, sans rédiger de prompt. Dans notre cas, MPNet transforme chaque tweet en un vecteur de 768 nombres. Le cosinus compare l'orientation de deux vecteurs u et v :

$$\cos(u, v) = (u \cdot v) / (||u|| \times ||v||)$$

Une paire de même sentiment reçoit la cible 1 ; une paire de sentiments différents reçoit 0. Une paire positive peut donc contenir deux tweets négatifs. La perte utilisée ici est la moyenne des écarts au carré entre le cosinus et la cible :

$$t_ij = 1 \text{ si } y_i = y_j, \text{ sinon } 0$$

$$L = (1/M)\ \Sigma\ [\cos(f\theta(x_i), f\theta(x_j)) - t_ij]^2$$

fθ est l'encodeur, x un texte, y son label et M le nombre de paires. Blog SetFit, Jo et al. (2022). Le blog explique les deux phases et montre du code avec MPNet. Après l'adaptation, une régression logistique classe les vecteurs. Pour un vecteur z, des poids w et un biais b, elle calcule :

$$p(\text{positif} \mid z) = 1 / (1 + \exp(-(w \cdot z + b)))$$

Par exemple, si le cosinus vaut 0,8 pour une paire de même classe, son erreur est (0,8 − 1)² = 0,04. Les paires réutilisent les textes ; elles ne créent pas de nouvelles annotations. Le préentraînement apporte aussi des connaissances : le modèle n'apprend pas toute la langue avec nos 1 024 tweets.

Blog SetFitABSA, Laperdon et al. (2023). Les auteurs réutilisent SetFit pour le sentiment par aspect : « écran agréable, batterie décevante » contient deux sentiments. Après extraction de candidats, un premier SetFit distingue aspect/non-aspect (deux classes) et un second prédit négatif, neutre ou positif (trois classes). Cette extension n'est pas entraînée ici ; elle constitue une piste d'amélioration.

Le lien entre les sources est direct : l'article présente le concept, le premier blog le met en pratique et le second l'adapte à une tâche plus fine. Notre application conserve le sentiment global. Les appels suivent le Quickstart officiel 1.1.3 sur SST-2, adapté à Sentiment140 ; le blog utilise SentEval-CR.

La modélisation

Le notebook réunit les deux méthodes. La graine 42 fixe les tirages. Il recharge par défaut les modèles sauvegardés ; les blocs d'entraînement restent disponibles. Aucun réglage n'est sélectionné sur le test.

Choix	BiLSTM + GloVe	SetFit + MPNet
Train	300 000 tweets	512 par classe, soit 1 024
Validation	25 000 tweets	1 000 par classe, soit 2 000
Représentation	GloVe 200 dimensions	Phrase de 768 dimensions
Apprentissage	Adam, taux 0,001	Adaptation, taux 0,00002
Entraînement	Lots de 256, 5 époques au plus	Lots de 16, 1 époque, 10 itérations de paires

Le BiLSTM utilise 30 000 entrées et des séquences de 40 mots : le maximum observé après nettoyage du train est 37. GloVe Twitter initialise des vecteurs de mots entraînables de 200 dimensions. Le LSTM lit dans les deux sens, avec 128 unités par direction, un dropout de 0,3 et une sortie binaire. La perte est BCEWithLogitsLoss. Le meilleur état est retenu sur validation, avec arrêt après deux époques sans amélioration et seuil fixé à 0,5. Les tailles et taux sont des réglages pratiques, non des optima démontrés.

Le nettoyage de la baseline retire URL, mentions, hashtags et ponctuation, puis passe en minuscules. SetFit conserve la casse et la ponctuation, normalise URL et mentions, transforme les caractères pictographiques en descriptions et réduit les répétitions. Le signe # est retiré sans segmentation des mots. Le dashboard partage le nettoyage SetFit.

Métrique et optimisation

$$\text{Précision} = \text{TP} / (\text{TP} + \text{FP}) \text{ ; rappel} = \text{TP} / (\text{TP} + \text{FN})$$

$$\text{F1} = 2 \times \text{précision} \times \text{rappel} / (\text{précision} + \text{rappel})$$

$$\text{F1 macro} = (\text{F1 négatif} + \text{F1 positif}) / 2$$

TP désigne les exemples de la classe bien retrouvés, FP les prédictions à tort dans cette classe, FN ses exemples manqués.

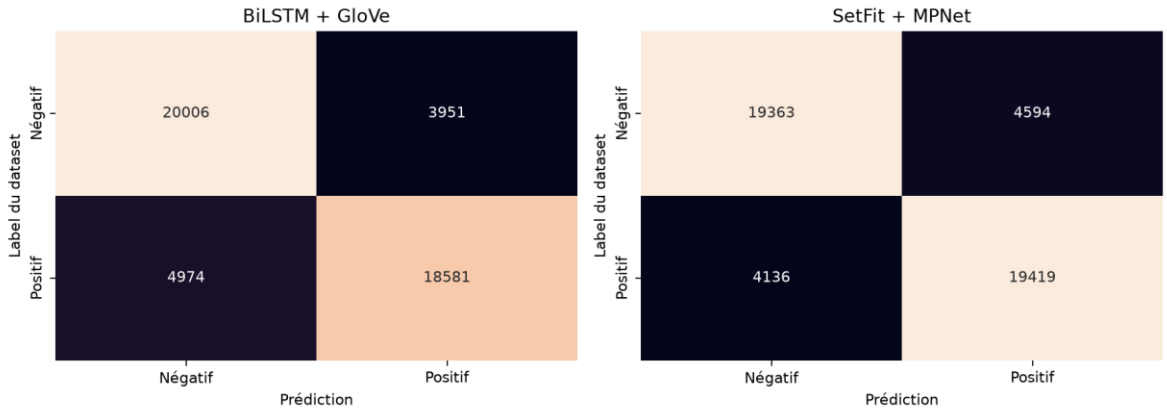
Le F1 macro donne le même poids aux deux sentiments. Les pertes entraînent les poids ; le F1 sert à évaluer les prédictions. Le BiLSTM maximise le F1 de validation et retient son meilleur état, obtenu à l'époque 2. Pour SetFit, les 512 tweets par classe, l'époque unique et le taux d'adaptation sont fixés pour limiter le calcul, puis évalués sur validation. Ils ne résultent pas d'une recherche systématique. Les 64 sous-mots limitent les séquences pendant l'entraînement ; ce n'est pas un nombre de mots.

Une synthèse des résultats

Les modèles prédisent les mêmes 47 512 tweets dans le même ordre. Les métriques sont exportées par le notebook, puis lues par le dashboard.

Modèle	Train	Accuracy	F1 macro
BiLSTM + GloVe	300 000	0,8122	0,8120
SetFit + MPNet	1 024	0,8163	0,8163

SetFit gagne 0,004273 de F1, soit 0,427 point de pourcentage. Son train contient environ 293 fois moins d'exemples. Ce ratio exclut le préentraînement et la validation ; il ne mesure pas des heures d'annotation économisées.



Matrices : lignes = labels du dataset, colonnes = prédictions. SetFit retrouve 838 positifs de plus, mais classe aussi 643 négatifs supplémentaires comme positifs : le bilan est de 195 bonnes réponses de plus. Le rappel négatif baisse de 83,51 % à 80,82 % : il faudrait donc confirmer ce choix pour détecter des plaintes.

Durée	BiLSTM	SetFit
Entraînement historique	697,7 s	2 582,0 s
Inférence du test sur CPU	3,1 s	370,5 s

Les temps d'entraînement sont historiques. L'inférence est mesurée hors chargement et nettoyage, avec des lots différents. SetFit est plus lent dans ces mesures. Le gain de score reste faible ; le choix métier dépend aussi du coût des données et du type d'erreur à éviter.

L'analyse de la feature importance globale et locale du nouveau modèle

Les coefficients logistiques portent sur les dimensions de l'embedding, pas directement sur les mots. Pour expliquer une prédiction, on retire successivement un mot et on mesure la variation de probabilité positive.

$$\Delta_\text{mot} = \text{p}(\text{positif} \mid \text{texte}) - \text{p}(\text{positif} \mid \text{texte sans le mot})$$

Une variation positive indique que la présence du mot soutient le positif dans ce contexte ; une variation négative soutient le négatif. Exemple : My Favourite website is down, prédit négatif.

Mot retiré	Variation de probabilité positive
down	−0,9961
website	−0,9959
is	−0,0085

Retirer down augmente fortement la probabilité positive : sa présence contribue à la décision négative. L'effet de website rappelle que les mots interagissent et que retirer un mot peut déformer la phrase.

La synthèse globale calcule la moyenne des variations absolues sur 100 tweets, avec 50 de chaque classe. On conserve les mots observés au moins trois fois.

Mot	Moyenne de |Δ|	Occurrences
see	0,3463	3
down	0,3325	3
didn't	0,3322	3
when	0,3290	3
want	0,3258	3

Cette analyse décrit l'échantillon, pas tout le corpus. Les probabilités ne sont pas calibrées et les effets ne sont pas causaux. Les mots peu observés rendent le classement fragile. Pour le renforcer, il faudrait élargir l'échantillon et vérifier la stabilité des effets sur plusieurs contextes. Le nuage de mots du dashboard décrit seulement des fréquences.

Les limites et les améliorations possibles

Les labels sont automatiques et les tweets anciens. Les modèles diffèrent par leurs représentations, nettoyages et budgets : l'écart ne mesure pas seulement l'effet de SetFit. La validation initiale contient 421 textes présents dans le train et un seul entraînement est disponible par modèle.

Les améliorations prioritaires sont des partitions nettoyées avant entraînement, plusieurs graines, des budgets identiques et un nouveau test annoté manuellement. Comparer MPNet gelé à MPNet adapté isolerait l'apport contrastif. Une calibration et des explications sur davantage de textes amélioreraient l'interprétabilité.

Dashboard et parcours utilisateur

Le parcours répond à trois questions : quelles données sont analysées, quel sentiment est prédit pour un message, et quel modèle choisir ? L'utilisateur filtre les sentiments et explore les graphiques, teste un tweet, puis consulte les performances et leur compromis. Les graphiques sont interactifs et les valeurs sont aussi disponibles en tableaux.

Les cinq critères demandés sont pris en compte : descriptions et texte alternatif (1.1.1), libellés et motifs en complément des couleurs (1.4.1), texte foncé sur fond clair et accent assombri (1.4.3), affichage adaptable au zoom et tableaux de remplacement (1.4.4), titre de page descriptif (2.4.2). Les contrôles locaux ne constituent pas une certification WCAG complète.

Les fichiers du modèle sont hébergés sur Hugging Face ; Streamlit exécute les prédictions. Le déploiement utilise le dépôt GitHub sur Streamlit Community Cloud. La version web doit être mise à jour avec les fichiers locaux et vérifiée sur son URL avant la soutenance.

Références

Tunstall et al. (2022). Efficient Few-Shot Learning Without Prompts. https://arxiv.org/abs/2209.11055

Jo et al. (2022). SetFit: Efficient Few-Shot Learning Without Prompts. https://huggingface.co/blog/setfit

Laperdon et al. (2023). SetFitABSA. https://huggingface.co/blog/setfit-absa

Go et al. (2009). Sentiment140. https://cs.stanford.edu/people/alecmgo/papers/TwitterDistantSupervision09.pdf

Hugging Face. SetFit 1.1.3, Quickstart. https://huggingface.co/docs/setfit/v1.1.3/en/quickstart

W3C. WCAG 2.1. https://www.w3.org/TR/WCAG21/