Classification de sentiments avec SetFit

Preuve de concept sur Sentiment140

Allan CHARDON
Projet 9
Novembre 2026

Objectif de la preuve de concept

Prédire le sentiment positif ou négatif de tweets en anglais.

Comparer SetFit à un modèle de référence : le BiLSTM.

Comparer les scores, les données utilisées et le temps de calcul.

Présenter les prédictions dans un dashboard Streamlit.

Le dataset Sentiment140

Propriété	Choix du projet
Corpus	1 600 000 tweets en anglais
Classes	800 000 négatifs et 800 000 positifs
Labels	0 pour négatif, 4 converti en 1 pour positif
Origine des annotations	Labels déduits des émoticônes

Des données nombreuses, avec des erreurs possibles dans les labels.

Veille sur SetFit

Article SetFit, 2022 : la méthode de référence.

Blog SetFit, 2022 : explication et exemple de code avec MPNet.

Blog SetFitABSA, 2023 : adaptation au sentiment par aspect.

Mon application : prédire le sentiment global de tweets.

Plan de comparaison

Étape	BiLSTM	SetFit
Train utilisé	300 000 tweets	1 024 tweets
Validation utilisée	25 000 tweets	2 000 tweets
Test corrigé commun	47 512 tweets	47 512 tweets
Critère principal	F1 macro	F1 macro

Même test pour les deux modèles. Tirages fixés avec la graine 42.

Contrôle des doublons

50 000 tweets au départ

2 488 lignes retirées

47 512 tweets dans le test corrigé

Retrait des textes déjà vus dans le train ou la validation,
des textes vides et des répétitions après nettoyage.

La baseline BiLSTM avec GloVe

GloVe représente chaque mot par une liste de nombres.

Le BiLSTM lit la phrase dans les deux sens.

Il apprend ensuite à prédire le sentiment.

La validation permet de garder le meilleur état du modèle.

Le fonctionnement de SetFit

1. MPNet représente le tweet par 768 nombres : son vecteur.

2. Des paires de tweets adaptent MPNet : même sentiment, cible 1. Sentiments différents, cible 0.

3. Erreur d'une paire = (similarité − cible)².

4. Une régression logistique prédit le sentiment à partir du vecteur.

Évaluer et choisir les réglages

Élément	Signification	Usage
F1 macro	Score moyen des deux sentiments	Critère principal
Accuracy	Part de prédictions correctes	Lecture complémentaire
Validation	Suivre les choix de modélisation	Séparer du test final

BiLSTM : meilleur état sur validation. SetFit : réglages fixes.
Le test commun ne sert pas à choisir les paramètres.

Préparation du texte

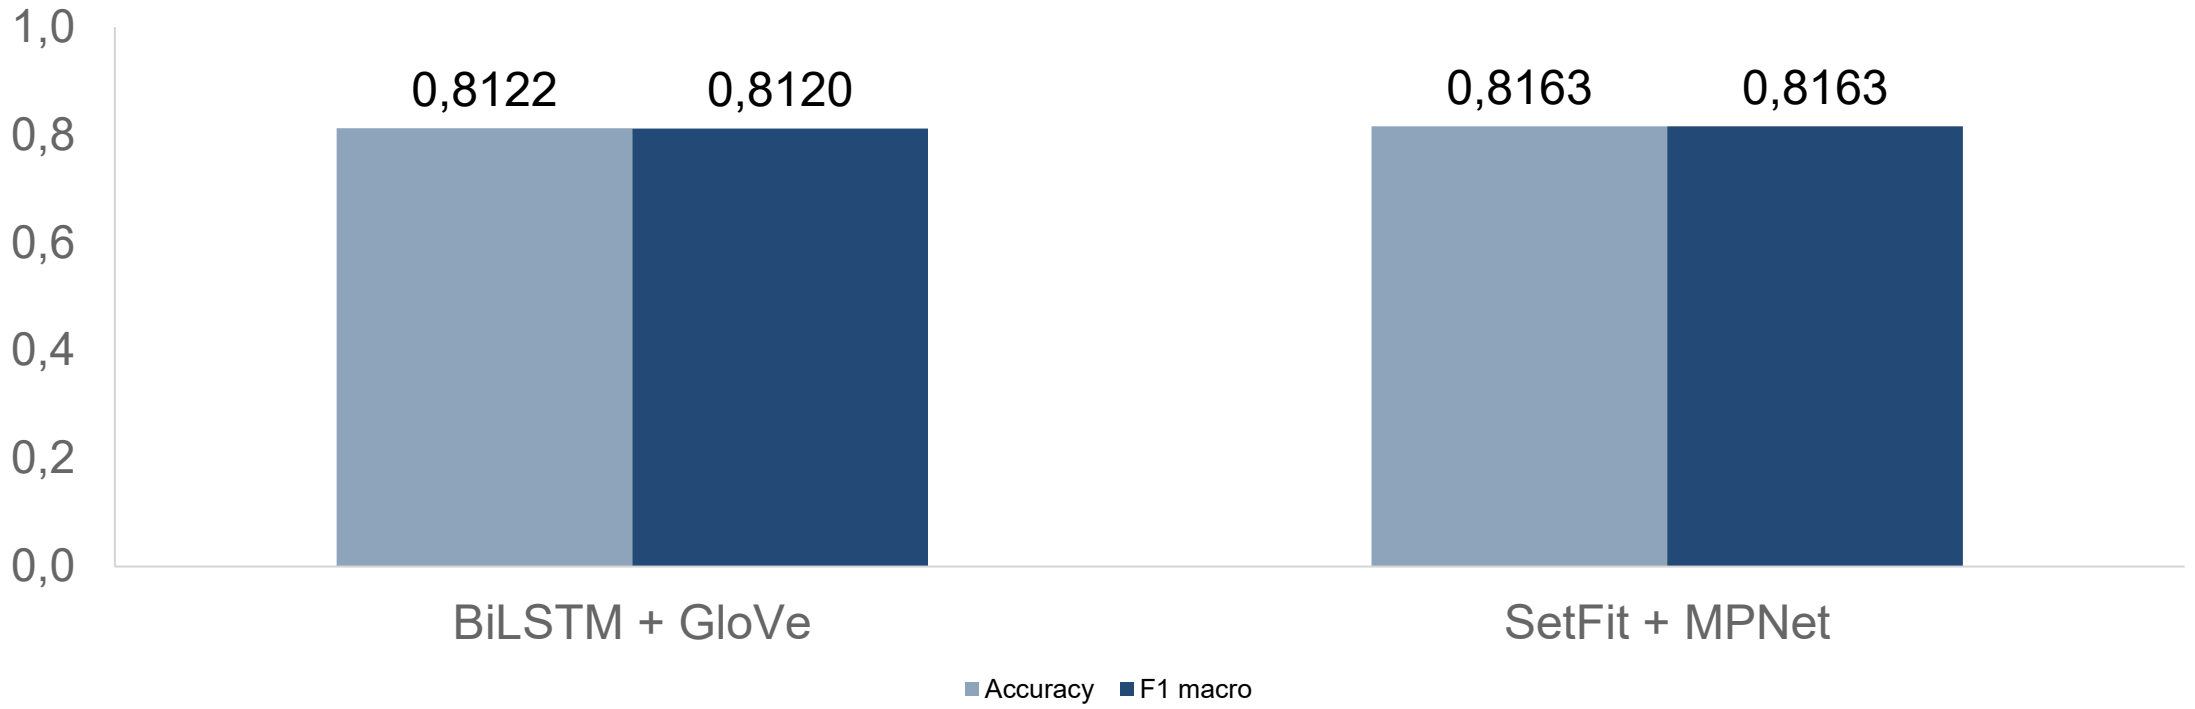
BiLSTM : minuscules, suppression de la ponctuation,
des URL, mentions et hashtags.

SetFit : ponctuation et casse conservées, URL remplacées
par http et mentions par @user.

Les émojis deviennent des descriptions.
Les longues répétitions de lettres sont réduites.

Le même nettoyage SetFit est utilisé pour les prédictions.

Résultats sur le test corrigé



F1 macro : 0,8120 contre 0,8163.
Gain SetFit : 0,427 point de pourcentage.

Interprétabilité globale

Retirer les mots et observer les changements sur 100 tweets.

Mot	Amplitude moyenne de l’effet	Occurrences
see	0,3463	3
down	0,3325	3
didn't	0,3322	3

Ce classement dépend des 100 tweets étudiés.
Le nuage de mots montre seulement les mots fréquents.

Matrices de confusion

BiLSTM + GloVe

Label réel	Prédit négatif	Prédit positif
Négatif	20 006	3 951
Positif	4 974	18 581

SetFit + MPNet

Label réel	Prédit négatif	Prédit positif
Négatif	19 363	4 594
Positif	4 136	19 419

SetFit : 195 bonnes réponses de plus au total.
Mais le rappel négatif baisse de 83,51 % à 80,82 %.

Budget de données et coût de calcul

Indicateur	BiLSTM	SetFit
Exemples labellisés	300 000	1 024
Entraînement historique	697,7 s	2582,0 s
Inférence du test corrigé	3,1 s	370,5 s

Environ 293 fois moins d’exemples pour l’adaptation.

SetFit est plus lent dans ces mesures.

Interpréter une prédiction

My Favourite website is down

Retirer un mot, puis comparer le score positif.

Mot retiré	Variation du score positif
down	-0,9961
website	-0,9959
is	-0,0085

Dans cette phrase, down contribue à la décision négative.
Retirer un mot peut aussi déformer la phrase.

Un dashboard simple et accessible

Explorer les données, tester un message, comparer les modèles.

Descriptions, tableaux et motifs en complément des couleurs.

Texte lisible, contraste renforcé et affichage au zoom à 200 %.

Titre de page explicite et texte alternatif du nuage de mots.

Démonstration du dashboard

1. Filtrer les sentiments et survoler les graphiques.

2. Tester un message positif puis un message négatif.

3. Choisir un exemple et comparer sa prédiction au label.

4. Comparer les scores et ouvrir les valeurs en tableau.

Conclusion et limites

SetFit : F1 macro 0,8163, avec 1 024 tweets d’adaptation.

Un intérêt quand peu de textes sont annotés.

Un faible gain de score et des prédictions plus lentes ici.

À confirmer avec autant de données, plusieurs tirages et un nouveau test.

Sources

Tunstall et al., 2022. Efficient Few-Shot Learning Without Prompts.
https://arxiv.org/abs/2209.11055

Jo et al., 2022. Blog SetFit, explication et exemple de code.
https://huggingface.co/blog/setfit

Laperdon et al., 2023. Blog SetFitABSA, adaptation du concept.
https://huggingface.co/blog/setfit-absa

Code : Quickstart SetFit 1.1.3 et CosineSimilarityLoss.
Liens complets dans la note méthodologique.