Classification de sentiments avec SetFit

Preuve de concept sur Sentiment140

Allan CHARDON
Projet 9
22 octobre 2026

Objectif de la preuve de concept

Prédire le sentiment positif ou négatif de tweets en anglais.

Comparer une méthode récente à une baseline déjà entraînée.

Mesurer la qualité prédictive et le besoin en données labellisées.

Présenter les prédictions dans le dashboard Streamlit existant.

Le dataset Sentiment140

Propriété	Choix du projet
Corpus	1 600 000 tweets en anglais
Classes	800 000 négatifs et 800 000 positifs
Labels	0 pour négatif, 4 converti en 1 pour positif
Origine des annotations	Émoticônes utilisées comme supervision distante

Une ressource abondante, avec des labels potentiellement bruités.

Veille sur SetFit

Article SetFit, 2022 : la méthode de référence.

Blog SetFit, 2022 : explication et exemple de code avec MPNet.

Blog SetFitABSA, 2023 : adaptation au sentiment par aspect.

Notre application : sentiment global de tweets avec peu de données.

Plan de comparaison

Étape	BiLSTM	SetFit
Train utilisé	300 000 tweets	1 024 tweets
Validation utilisée	25 000 tweets	2 000 tweets
Test corrigé commun	47 512 tweets	47 512 tweets
Critère principal	F1 macro	F1 macro

Même test et même ordre des observations. Graine 42.

Contrôle des doublons

50 000 tweets au départ

2 488 lignes retirées

47 512 tweets dans le test corrigé

Exclusion des chevauchements avec le train et la validation,
des textes vides et des répétitions après nettoyage.

La baseline BiLSTM avec GloVe

Vocabulaire de 30 000 tokens construit sur le train uniquement.

GloVe Twitter : 200 dimensions. Séquences de 40 tokens.

LSTM bidirectionnel : 128 unités par direction, dropout de 0,3.

Adam et arrêt anticipé selon le F1 macro de validation.

Le fonctionnement de SetFit

1. MPNet encode chaque tweet en un vecteur de 768 dimensions.

2. Des paires de même classe ou de classes différentes adaptent l'encodeur par apprentissage contrastif.

3. Une régression logistique classe les embeddings adaptés.

L'inférence encode puis classe le texte, sans prompt.

Évaluer et choisir les réglages

Élément	Signification	Usage
F1 macro	Score moyen des deux sentiments	Critère principal
Accuracy	Part de labels retrouvés	Lecture complémentaire
Validation	Suivre les choix de modélisation	Séparer du test final

BiLSTM : meilleur état sur validation. SetFit : réglages fixes.
Le test commun ne sert pas à choisir les paramètres.

Préparation du texte

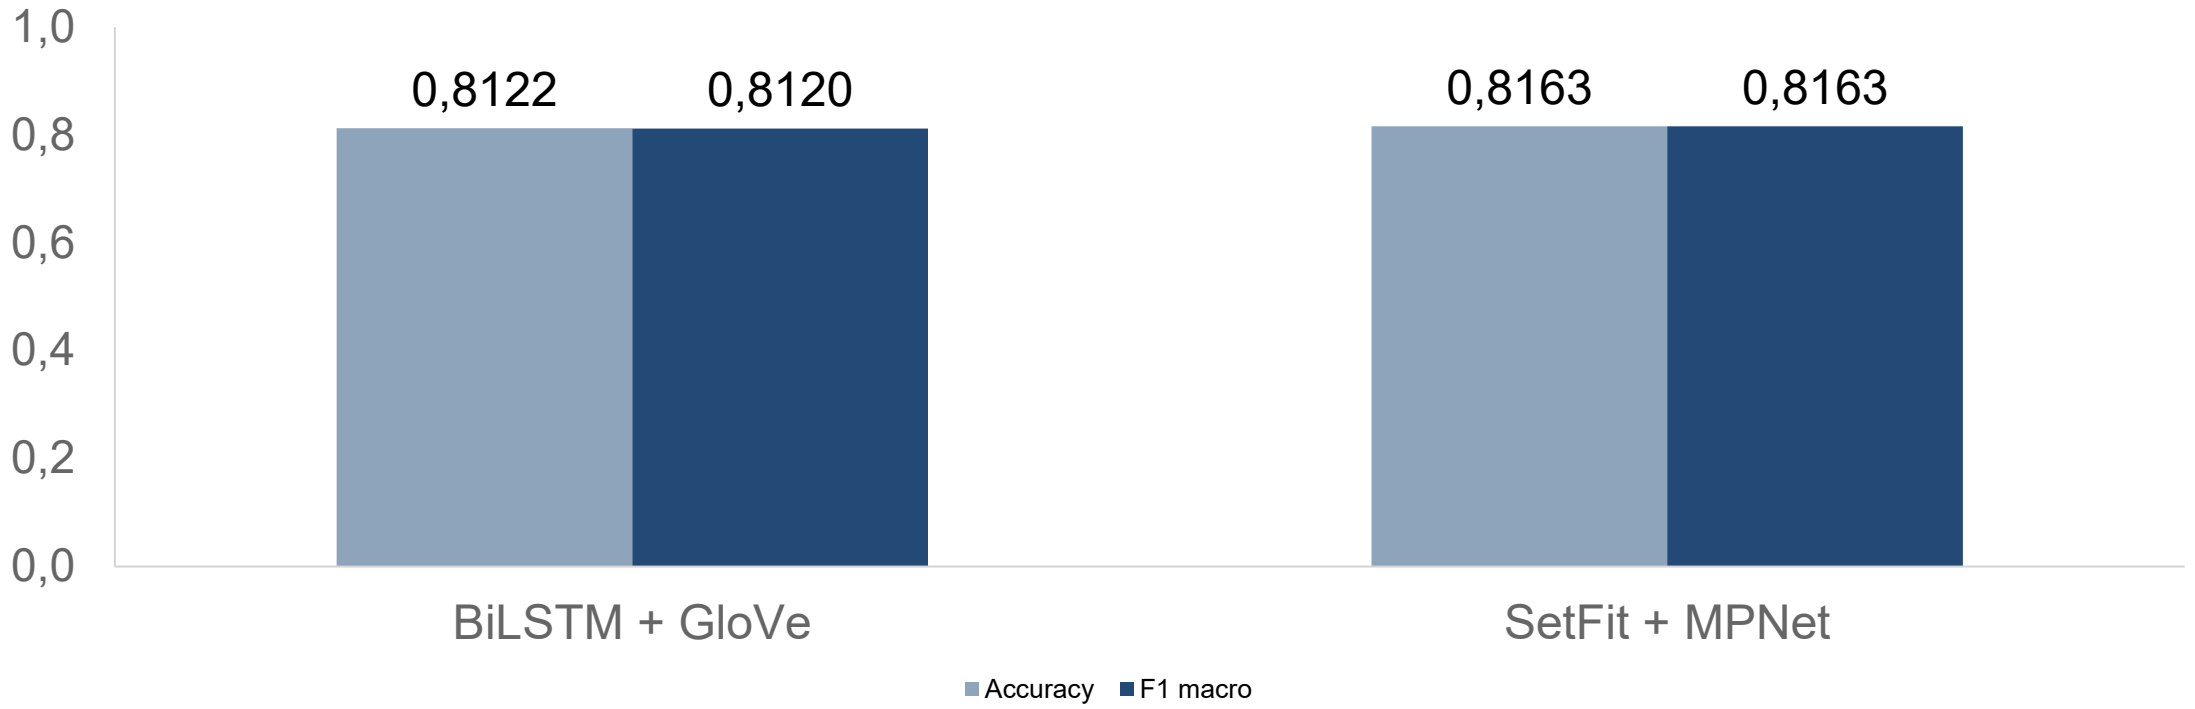
BiLSTM : minuscules, suppression de la ponctuation,
des URL, mentions et hashtags.

SetFit : ponctuation et casse conservées, URL remplacées
par http et mentions par @user.

Les caractères pictographiques deviennent des descriptions.
Les répétitions de lettres sont réduites.

Le même nettoyage SetFit est utilisé pour les prédictions.

Résultats sur le test corrigé



F1 macro : 0,8120 contre 0,8163.
Gain SetFit : 0,427 point de pourcentage.

Interprétabilité globale

Moyenne des effets de suppression sur 100 tweets.

Mot	Variation absolue moyenne	Occurrences
see	0,3463	3
down	0,3325	3
didn't	0,3322	3

Cette synthèse décrit un échantillon, pas tout le corpus.
La fréquence d’un mot et son effet sur le modèle sont différents.

Matrices de confusion

BiLSTM + GloVe

Label réel	Prédit négatif	Prédit positif
Négatif	20 006	3 951
Positif	4 974	18 581

SetFit + MPNet

Label réel	Prédit négatif	Prédit positif
Négatif	19 363	4 594
Positif	4 136	19 419

Les deux classes comptent dans le F1 macro.
Les erreurs restent nombreuses malgré des scores proches de 0,82.

Budget de données et coût de calcul

Indicateur	BiLSTM	SetFit
Exemples labellisés	300 000	1 024
Entraînement historique	697,7 s	2582,0 s
Inférence du test corrigé	3,1 s	370,5 s

Environ 293 fois moins d’exemples pour l’adaptation.

SetFit ne présente pas d’avantage de vitesse dans ces mesures.

Interpréter une prédiction

My Favourite website is down

Retirer un mot, puis comparer la probabilité du sentiment positif.

Mot retiré	Variation de P positif
down	-0,9961
website	-0,9959
is	-0,0085

Dans cette phrase, down contribue à la décision négative.
L'effet reste lié au contexte et ne mesure pas une causalité.

Un dashboard simple et accessible

Explorer les données, tester un message, comparer les modèles.

Descriptions, tableaux et motifs en complément des couleurs.

Texte lisible, contraste renforcé et affichage au zoom à 200 %.

Titre de page explicite et texte alternatif du nuage de mots.

Démonstration du dashboard

1. Filtrer les sentiments et survoler les graphiques.

2. Tester un message positif puis un message négatif.

3. Choisir un exemple et comparer sa prédiction au label.

4. Comparer les scores et ouvrir les valeurs en tableau.

Conclusion et limites

SetFit : F1 macro 0,8163, avec 1 024 exemples de train.

Un intérêt lorsque les données labellisées sont limitées.

Gain de score faible et inférence plus lente dans ces mesures.

À confirmer : budgets identiques, plusieurs graines et nouveau test.

Sources

Tunstall et al., 2022. Efficient Few-Shot Learning Without Prompts.
https://arxiv.org/abs/2209.11055

Jo et al., 2022. Blog SetFit, explication et exemple de code.
https://huggingface.co/blog/setfit

Laperdon et al., 2023. Blog SetFitABSA, adaptation du concept.
https://huggingface.co/blog/setfit-absa

Documentation officielle SetFit 1.1.3.
https://huggingface.co/docs/setfit/v1.1.3/en/quickstart